

Learning Similarity Matrix Representations for Music Tagging via Vision-Language Model

Group1 蘇晟翔、金昆樂、廖曉威


一、Introduction

1. 動機


本研究之核心動機為：MIR 領域中傳統上主要使用頻譜圖（Spectrogram）作為深度學習模型的輸入，但我們能否改成使用自相似矩陣（SSM）與互相似矩陣（CSM）作為模型輸入，以求幫助模型更好的捕捉音樂中的高階語意資訊？

MIR 領域中，Spectrogram 等時頻表示長期佔據主流。這類特徵建立在時間與頻率的座標系上，屬於對原始訊號的一階統計性描述。這類表徵雖能有效描述完整的局部聲學細節，卻較難直接映射至曲風、樂器、情緒等高階語意，因為語意資訊往往不是由單點特徵決定，而更依賴於跨時間的結構關係。

相較之下，SSM 透過描述音樂自身相似度反映重複結構與長程相似性；本篇中的 CSM 則用於刻畫音樂訊號與自訂模板之間的相似關係。這類表示透過相似性函數對特徵空間進行提煉形成二階統計特徵，將特徵從「局部訊號的觀測值」提升為「片段之間的關係分布」，在幾何紋理中隱含了豐富的高階語意。




Spectrogram



SSM/CSM

近年來，MIR 領域已出現音訊-語言模型（ALM）跨模態對齊方法，將頻譜圖與高階的文字語意對齊。另一方面，過去亦有將 SSM/CSM 作為影像輸入的研究，但多著重於局部紋理辨識與結構分析，至今尚未有研究嘗試將 SSM/CSM 這種幾何紋理用於至視覺-語言模型（VLM）中與高階的文字語意進行對齊。



基於以上，我們認為 SSM/CSM 將音樂從原始訊號轉換為幾何表示，蘊含更豐富的高階語意。因此或許具備直接作為 VLM 輸入進行語意對齊的巨大潛力。

2. 主任務: Music Tagging

根據上述特性，本研究選擇 Music Tagging 作為主要任務。Music Tagging 著重於全局語意理解，這種特性恰好與上述的動機契合，若模型僅憑藉 SSM/CSM 即可達成優異的標籤分類，將有力地支持其作為 MIR 通用表徵的潛力。


本研究亦進一步探討組合式提示詞（Compositional Prompt）的應用。在 Music Tagging 任務中，標籤之間往往存在關聯性[5]，現有研究多透過 GNN 等顯式結構來處理；而近期 MIR 論文中常使用 LLM 來生成多樣化的自由文本提示詞。考量到自由文本生成的不穩定性以及較高成本，本研究嘗試設計結構化且規則化的提示詞來建模標籤間的關聯（e.g. "A music featuring [instrument] in the [genre] style with a [mood] mood."），其優點是可以根據標籤快速的大量生產文本，因此我們藉此來探索組合式提示詞在 Music Tagging 任務中的有效性。

3. 使用 SSM/CSM 作為 VLM 輸入的潛在優勢

首先，不同的 Spectrogram 產生的 SSM/CSM 具備不同特性，對應不同的音樂語意。而圖片是一種三通道的資料，此結構可以方便地整合不同 Spectrogram 產生的 SSM/CSM 於同一圖片中（下圖左），使這些資訊自然的融合互補，並且還能依據下游應用靈活調整輸入的資訊，提升任務適應性與泛化能力。

此外，在影像層級進行的操作具有更多的可能性，於資料增強上也或許具備更多選擇。例如下圖中所示，傳統基於 Spectrogram 的模型對於輸入音訊的長度以及 sample rate 有較嚴格的要求。但若是圖片輸入，3s 與 10s 的音訊都可以自然地轉換成相同大小的圖片來輸入模型，讓模型具備多尺度的感知能力。

再者，SSM/CSM 經過仔細設計，或可在資訊壓縮與計算效率上具備優勢。例如下圖中將 10s 產生的 313x313 pixel 圖片轉成 224x224 pixel 的輸入送進模型、亦或是下圖右對於 CSM 產生的長方形圖片切割拼裝成新的正方形圖，這兩者都可以達到資訊壓縮的效果。整體而言，SSM/CSM 不僅只是提供一種視覺化輸入形式，更是一個可進行多樣化操控的資料表示方式。



二、Framework

1. SSM/CSM 生成


對於 SSM，我們使用 Mel-Spectrogram、Chroma_STFT (Chroma Short-Time Fourier Transform)、MFCC (Mel-Frequency Cepstral Coefficients) 這三者來生成三通道的圖片，這三者對於 Music Tagging 任務的 Instrument、Genre、Mood 三種標籤相輔相成。Mel-Spectrogram 作為基礎保留了大部分頻譜資訊，只是將頻率軸轉成符合人耳感知的 Mel-Scale，因此能幫助辨識 Instrument 跟 Genre 類別。Chroma STFT 重點在保留和聲資訊，因此能幫助辨識 Genre 跟 Mood。MFCC 像是音色摘要，最常用於協助辨識 Instrument。

對於 CSM，則是與一段 C2 到 C7 均勻分布的音訊來計算相似度生成三通道的圖。相較於 SSM，CSM 透過與固定參考音訊進行比較，能較完整的保留完整的音樂資訊。並且將 MFCC 換成 CQT (Constant-Q Transform)，因為 MFCC 重點是音色，但我們是與固定音訊計算因此使用 MFCC 並不合理。CQT 使用 Log Scale 對齊音高結構，能保留和聲與調性資訊，同樣適合辨識 Genre 跟 Mood。

2. 模型架構

我們使用 Contrastive Language-Image Pre-training (CLIP) 作為 Backbone，並使用以下數種變體來進行實驗。


A. BasicCLIP – SSM 3s



將 raw data(29 秒)切成 9 段 3 秒鐘，透過 librosa 產生頻譜圖來計算 SSM，組成 RGB 三通道圖片，Training 時從 9 個片段中隨機抽一個，Testing 則測試所有片段後取平均。另一方面我們將所有 tags 轉換成一段文字(e.g, “This is a music featuring {tag}”)。最後將圖和文字送進各自的 encoder 得到兩個 characteristic vector，計算兩者相似度夾角就是模型的預測分數。訓練時將此結果與標籤(GT)


計算 BCE loss，測試時則是平均所有片段的分數作為最終結果。

B. BasicCLIP – SSM 10s




為了實驗不同時間長度片段的差異，SSM 10s 與 SSM 3s 不同的地方是在切分音檔時，切成 9 個 10 秒鐘的片段，且彼此之間有重疊，其餘與 SSM 3s 一致。

C. BasicCLIP – CSM



我們將 SSM 換成 CSM，其餘架構與原本一致。

D. MixCLIP



在 MixCLIP 中，除了 BCE Loss，我們進一步引入跨模態對比學習。對於每個樣本，其所有標籤會被組合成一段文字，例如：“A [piano] (Inst.) [jazz piece] (Genre) with a [calm mood] (Mood).”，透過 text encoder 編碼得到 batch 內 N 首歌曲對應的 text characteristic vectors。同時每個樣本的 SSM 也會得到對應的 image characteristic vectors。接著計算所有 image-text 配對的相似度，形成一個 $N \times N$ 的相似度矩陣，其中第 (i, j) 項表示第 i 首音訊與第 j 首文本描述之間的相似度。訓練時，我們將同一首音訊與其對應文本的配對也就是所有 (i, i) 配對視為正樣本，其餘非配對組合作為負樣本，以 InfoNCE loss 進行優化，使正樣本對的相似度最大化，而負樣本對的相似度最小化。

三、Experiment

1. 資料集

使用 MagnaTagATune[1]資料集，並且根據[2]的實驗設置，編號 0~B 為訓練集，13 為驗證集，14~16 為測試集。具體標籤清理則根據[3]，篩選出 top50 標籤、進行去重跟分類 (例如 'beat'、'beats' 視為同一類)，清理後剩 38 個如下。
(p.s. 此處不確定是否該進行去重)

類別	標籤
genre	'classical', 'techno', 'electro', 'rock', 'india', 'opera', 'pop', 'new age', 'dance', 'country', 'heavy'
instrument	'guitar', 'string', 'drum', 'piano', 'violin', 'vocal', 'synth', 'female', 'male', 'singer', 'no singer', 'harpsichord', 'flute', 'sitar', 'choir', 'female vocal', 'harp', 'cello'
mood	'slow', 'fast', 'ambient', 'loud', 'quiet', 'soft', 'strange'
etc	'beat', 'solo'

- 我們對清理完的資料進行統計，顯示了多標籤分類任務的特性：一個樣本可能有多個標籤，也可能只有一個標籤，甚至同一類可能會有多個標籤。

```
◆ 單類別樣本數：4477 個 (21.10%)
◆ 多類別樣本數：16737 個 (78.90%)

📁 各大類別涵蓋率統計 (至少包含該大類 1 個標籤)：
  ▣ 含有 [genre      ] 標籤的樣本數：13713 個 (64.64%)
  ▣ 含有 [instrument] 標籤的樣本數：17509 個 (82.54%)
  ▣ 含有 [mood       ] 標籤的樣本數：8455  個 (39.86%)

🔥 同時具備三種標籤的樣本數：4505 個 (21.24%)
```


2. 實作細節

- 由於運算資源限制，在訓練上僅使用 2030 首，約訓練集 13% 的訓練資料；驗證集則使用 50% 共 767 首，測試集則是使用全部 4354 首。
- 使用三個評估指標：
 - ROC-AUC：專注於全局的相對排序能力，評估模型能否有效地將負樣本往後推。
 - PR-AUC：由於音樂標籤分布高度不平衡，並且正樣本稀少，PR-AUC 專注於正樣本的預測，因此更能反映模型對少樣本類別的預測能力。
 - F1-Score：衡量在明確分類閾值下，Precision 與 Recall 的平衡表現。

3. 實驗結果

● Ours v.s. CLAP

Model	PR-AUC (Test)	ROC-AUC (Test)	F1 Score (Test)
CLAP (3s)	42.57%	85.32%	38.99%
Basic CLIP (SSM 3s)	38.75%	86.36%	44.50%
Basic CLIP (SSM 10s)	37.81%	86.39%	44.25%
Basic CLIP (CSM 3s)	39.58%	87.61%	45.47%
mix CLIP (SSM 3s)	<u>39.97%</u>	86.99%	<u>45.29%</u>
mix CLIP (CSM 3s)	38.94%	<u>87.11%</u>	44.13%

不經過微調的 CLAP 在 Zero-shot 盲測下有最高的 PR-AUC，反映出 CLAP 能看到 Spectrogram 的完整資訊，更精準地抓到正樣本。相較之下 CLIP 使用 SSM/CSM 不可避免會流失的細部特徵，較高的 ROC-AUC 顯示其整體排序能力不錯，但在高分區域混入了較多 False Positives，因此 PR-AUC 被拉低。

● SSM v.s. CSM

Model	PR-AUC (Test)	ROC-AUC (Test)	F1 Score (Test)
Basic CLIP (SSM 3s)	38.95%	86.36%	44.50%
Basic CLIP (CSM 3s)	<u>39.79%</u>	87.61%	45.47%
mix CLIP (SSM 3s)	40.20%	86.99%	<u>45.29%</u>
mix CLIP (CSM 3s)	39.15%	<u>87.11%</u>	44.13%

對於 SSM 與 CSM，兩者表現非常接近。因此我們認為這兩種矩陣或許可以扮演資料增強的角色，同時輸入這兩種特徵給模型，為模型提供更多元的資料。

● Compositional Prompt

Model	PR-AUC (Test)	ROC-AUC (Test)	F1 Score (Test)
Basic CLIP (SSM 3s)	38.95%	86.36%	44.50%
Basic CLIP (CSM 3s)	<u>39.79%</u>	87.61%	45.47%
mix CLIP (SSM 3s)	40.20%	86.99%	<u>45.29%</u>
mix CLIP (CSM 3s)	39.15%	<u>87.11%</u>	44.13%

表中的 Mix CLIP 是 Basic CLIP 加上 Compositional Prompt 的版本，雖然在表現上沒有太大差異。但在訓練時，Mix CLIP 僅使用了 60% 的迭代次數就達到 Basic CLIP 的程度。這證實了結構化的語意描述能夠在多模態共享空間中，幫助模型更快建立起視覺與音樂語意之間的橋樑。

● 3s v.s 10s

測試時間切片長度的影響。3s 片段在圖像化後為 94* 94 像素，10s 片段則為 313*313 像素，兩者都會縮放至 CLIP 的 224*224 像素。3s 與 10s 的效能差不多代表圖像具有可壓縮性，即使將 10s 片段略為壓縮仍有具有不錯的表現。當然此處的實驗並不完整，還需要更多 5s、6s、15s、20s 等來進一步確認。

Model	PR-AUC (Test)	ROC-AUC (Test)	F1 Score (Test)
Basic CLIP (SSM 3s)	38.95%	86.36%	44.50%
Basic CLIP (SSM 10s)	38.00%	86.39%	44.25%

● 與其他現有方法比較

我們也有嘗試與其他現有論文比較以驗證實驗合理性，但由於我們對 Music Tagging 相關知識的缺乏，遇到了無法確切回答的問題。


首先下表是我們找到表現較好的其他論文[4]，由於我們使用較少的訓練集，並且也沒有精心調整過模型、跑多種 seed 等等，因此我們認為我們的方法的結果還有不少進步空間，相比之下已是蠻不錯的結果。

Model	PR-AUC (Test)	ROC-AUC (Test)
MusiCNN	44.93%	91.06%
Short-chunk CNN	45.90%	91.26%
CLAP	42.78%	85.32%
mix CLIP (SSM 3s)	<u>39.97%</u>	86.99%

但我們發現近年多篇論文在此數據集上的表現都比較低，並且這些論文中列出的 CLAP 性能也遠比我們測出的要低。目前想到的唯一可能是我們有將同義標籤進行合併（例如 ‘beat’, ‘beats’），而這些論文可能沒有，因此這些論文受到資料集標註不準確的干擾導致表現降低。

● T-SNE 視覺化

我們將各標籤透過文字編碼器輸出的 text embedding 使用 t-SNE 視覺化，觀察原本完全不了解這些詞的 CLIP 是否有學到正確資訊。可以看到 quiet、soft、sleep 這些標籤聚在一起、electro、techno、dance 這些電子舞曲類的標籤聚在一起等等。這在視覺上證實了，代表我們的模型不是在死記硬背。



四、Conclusion

最後總結成果：

第一，我們提出了「利用視覺模型（CLIP）直接從 SSM/CSM 中提取音樂高階特徵」的創新想法並說明其潛在優勢。

第二，實驗數據驗證了本方法在 Music Tagging 任務上的高度可行性。

五、目前缺陷

以下整理目前報告中我們有發現的、以及課堂報告時老師提到的問題。

1. 計算 SSM/CSM 具體應該使用多少時長?
 - 先前 Music Tagging 任務使用 3s 所以目前也沿用，但 3s 的 SSM/CSM 似乎沒有具體物理意義，一般來說這兩者都需要較長的時間(10s 以上)來算。
 - 但是使用太長的時間拿到的 SSM/CSM 又會是很大張的圖片，不易放進模型裡，因此這裡形成一項衝突。
2. 如果直接把 Spectrogram 裁剪成一張張圖片送進 VLM 呢?
3. 能否更具體解釋使用 SSM/CSM 跟 Spectrogram 的優點?
 - 實際設計並測試是否能省下更多的運算量?
 - 設計更具體影像層級的操作以及說明其對應的意義
4. 這個想法不應該沒人想過，但卻沒有查到相關論文，那具體問題會在哪裡?

六、參考資料

[1] Evaluation of algorithms using games: The case of music tagging

[2] End-to-end learning for music audio

[3] <https://github.com/keunwoochoi/magnatagatune-list>

[4] Evaluation of CNN-based Automatic Music Tagging Models

[5] Music Tagging with Classifier Group Chains